

PRISM

Privacy Regulation Intelligent Search Model

개인정보 보호법 RAG 챗봇 — 출처를 강제하고 낱조를 막는 법령 질의응답 시스템

github.com/yeodh10/PRISM | 현행 법률 제20897호(시행 2025-10-02) | 개인 프로젝트 · 2026

문제의식 & 목표

법률 도메인에서 LLM의 최대 위험은 그럴듯한 조문을 지어내는 환각이다. 한 글자만 틀려도 신뢰가 무너진다. PRISM은 정확성·근거·정직을 시스템 프롬프트와 코드로 이중 보장하는 RAG를 목표로 한다 — 검색된 조문에만 근거하고, 모르면 솔직히 “찾지 못함”이라 답한다.

아키텍처

질문 → 한국어 SBERT 임베딩(ko-sroberta-multitask, 768d, 로컬·무료) → Chroma 벡터검색(코사인) + 조문 상호참조 그래프(Hybrid) → Claude(opus-4-8, adaptive thinking) → 출처·고지 코드 후처리 → 답변

핵심 설계 — 환각 억제 5원칙 (코드 강제)

- 검색된 조문에만 근거 — 제공되지 않은 내용은 추측·생성 금지
- 출처 인용 강제 + 코드 검증 — [출처: 제29조(안전조치의무)] 형식. 검색 결과에 없는 조문을 인용하면 코드가 경고 배너를 부착
- 모르면 “찾지 못함” — 다른 지식으로 메우지 않음
- 면책 고지 코드 강제 — LLM이 누락해도 코드가 항상 부착
- 현행 기준 명시 — 미시행 개정분은 단정하지 않음

기술적 난제와 해결

- 환각 억제 = 출처 강제 — 검색 조문만 컨텍스트로 주입. 시행령 소관 수치(유출통지 일수)를 묻자 지어내지 않고 “확인할 수 없다”고 답함
- 한국어 임베딩 — ko-sroberta를 로컬 추론으로 채택해 API 비용 0·데이터 외부 미전송
- 법령 데이터 정확성(낱조 0) — law.go.kr 조문별 원문 + 독립 에이전트 교차검증, 핵심 37개 조문
- Windows Smart App Control × scipy — SAC가 scipy≥1.15의 _cyutility DLL을 차단 → 원인 진단 후 scipy<1.15 고정으로 해결
- 적대적 전수조사 → 코드 안전망 — 멀티에이전트 감사로 “출처 강제가 프롬프트 지시일 뿐”인 갭을 발견, 후처리(_finalize)로 코드 강제 + pytest로 회귀 방지

결과 & 검증

데이터	law.go.kr 원문 조문 37개 (수집·동의·위탁·국외이전·정보주체 권리·CPO·영향평가·과징금·벌칙 등)
검색 정확도	recall@4 0.923 · recall@1 0.885 · MRR 0.904 (큐레이션 26문항, LLM 비호출 평가)
품질 보증	pytest 25개 통과(안전 불변식·API 검증, LLM 비호출) · GitHub Actions CI
보안	레이트리미트 · CORS 설정화 · 뉴스 fetch SSRF·응답크기 가드 · 캐시 단일비행
UX	스펙트럴(프리즘 분광) UI · 다크모드 · 카테고리 컬러 · 개인정보·보안 뉴스 탭

기술 스택

Python · FastAPI · Anthropic Claude API · sentence-transformers · Chroma · 정적 HTML(의존성 0, FastAPI 직접 서빙) · pytest · GitHub Actions

본 시스템은 비공식 참고용이며 법률 자문이 아닙니다 · 데이터 출처: 국가법령정보센터(law.go.kr)